PENGWIN: detección, segmentación de fragmentos y desplazamiento en milímetros de fracturas pélvicas en tomografía computarizada

Carlos Andrés Orozco Caicedo · José David Mesa Ramírez · Sara Lucía Rojas Mejía · Esteban Cobo Gómez
Analítica de Datos · Universidad Autónoma de Occidente · 2026
Repositorio: https://github.com/ShadowBlack33/Proyecto-Analitica-de-Datos

Uso exclusivamente académico: no es un dispositivo médico ni está validado clínicamente.

Resumen

Para planear la cirugía de una fractura pélvica hay que saber, de cada fragmento de hueso, de qué hueso viene, dónde está y cuánto se movió. Construimos un sistema propio que responde esas tres preguntas sobre las tomografías computarizadas (TC) del reto PENGWIN, con dos partes: una red multitarea 2.5D con cabezas de clasificación, detección, segmentación y regresión de distancia, y un post-proceso 3D que mide el desplazamiento en milímetros. En los 15 pacientes de prueba llega a F1 de 0.981, mAP@0.50 de 0.906 y Dice de fragmento de 0.700; en la ablación, ni CBAM ni el transfer learning mejoraron el Dice. La limitación principal son los fragmentos desplazados que el modelo confunde con fragmentos en contacto.

1. Introducción

Hoy, identificar cada fragmento, asignarlo al sacro o a un coxal y estimar qué tan separado está de su hueso depende de que un experto lea la TC. Lo que buscamos fue automatizarlo: detectar cada región ósea en cada corte, segmentar y clasificar sus fragmentos, medir en milímetros la distancia de cada fragmento al fragmento principal y mostrar todo en un tablero interactivo. El curso no permitía usar YOLO, Detectron2 ni Mask R-CNN preentrenado, así que la red, la supresión de no máximos (NMS), el post-proceso y las métricas los hicimos nosotros. FCOS [4] lo consultamos solo para entender la detección sin anclas.

2. Datos

Usamos la tarea 1 (TC) del reto PENGWIN, MICCAI 2024 [1], [2]: 100 TC con máscaras de fragmentos revisadas por ortopedistas, en tres regiones (sacro, coxal izquierdo y coxal derecho) con hasta 10 fragmentos cada una. La partición es por paciente (70/15/15), nunca por corte, y está versionada con un hash. El análisis exploratorio guió varias decisiones: el espesor de corte (0.63–1.25 mm) y el tamaño del píxel (0.66–1.22 mm) cambian de un estudio a otro, así que toda distancia se calcula en milímetros con el espaciado del header. 34 volúmenes vienen rotados 180° y se reorientan con su matriz de dirección, sin interpolar; la intensidad del hueso (−4 a 1154 HU, percentiles 1–99) fijó la ventana en [−200, 1200] HU; y la distancia real de los secundarios a su hueso tiene mediana de 0.8 mm (máximo 73.1 mm), o sea que casi todos están en contacto con él.

3. Método

Arquitectura. La entrada es 2.5D: cada corte entra con sus dos vecinos, lo que da algo de contexto 3D sin salirse de la memoria de una GPU de 6 GB. El backbone es propio, de cinco bloques convolucionales (32 a 512 canales), y en el diseño base lleva CBAM [3] en los bloques 4 y 5. De ese backbone salen cuatro cabezas: una clasifica qué regiones

aparecen en el corte; otra las detecta sin anclas, sobre una grilla propia y con NMS propio; un decodificador tipo U-Net [5] segmenta la región, el rol del fragmento (principal o secundario) y el borde de contacto; y la última hace una regresión densa de la distancia en milímetros. El modelo final tiene 6.75 M de parámetros.

Pérdida. La pérdida total suma siete términos. Los pesos de cada término se calibraron igualando las normas de gradiente sobre el backbone compartido, para que ninguna tarea dominara el entrenamiento: $\lambda = 0.5$ (clasificación), 3.0 (objectness), 5.0 (cajas), 1.0 (región), 1.0 (rol), 2.0 (borde) y 0.5 (distancia). En la receta final la clase secundaria pesa el triple.

Entrenamiento y post-proceso. El modelo base se entrena a 256 px en cuatro etapas (detección, segmentación, distancia y ajuste conjunto) con precisión mixta. El modelo final se ajusta desde ese modelo a 384 px durante 20 épocas, con rotaciones de hasta 35° y un borde de contacto más grueso. Después las predicciones se apilan en un volumen: un watershed 3D separa los fragmentos y distance_transform_edt mide la distancia borde a borde de cada uno al principal, en milímetros, igual que sobre el ground truth. Los fragmentos de menos de 1 mL se descartan; ese umbral se eligió en validación.

Selección y cómputo. Antes de comparar modelos fijamos una regla: un cambio solo se adopta si sube el Dice de fragmento en validación en más de 0.01, y la prueba solo se reporta. Con esa regla se pasó de 256 a 384 px (0.695 a 0.719) y luego se quitó CBAM (0.719 a 0.793). Todos los modelos se entrenaron en una RTX 3060 Laptop de 6 GB, con una semilla por modelo (tabla 2).

4. Resultados

La tabla 1 compara el modelo final con los objetivos en los 15 pacientes de prueba: clasificación y detección superan las metas con margen, pero la segmentación de fragmentos queda por debajo (Dice de 0.700 frente a 0.85).

Tabla 1. Modelo final en prueba frente a los objetivos del proyecto.

Tarea	Métrica	Objetivo	Resultado
Clasificación	F1 / AUC	≥ 0.85 / 0.85	0.981 / 0.999
Detección	IoU de cajas	≥ 0.65	0.893
Detección	mAP@0.50 / [0.50:0.95]	≥ 0.65 / 0.40	0.906 / 0.767
Segm. de fragmento	Dice / IoU	≥ 0.85 / 0.70	0.700 / 0.628
Segm. de fragmento	HD95 / ASSD (mm)	opcional	23.2 / 5.3

Ablación (tabla 2). En las dos resoluciones, quitar CBAM sube la validación (+0.041 y +0.074) y casi no cambia la prueba (−0.009 y −0.019), dentro de lo que varía el resultado con 15 pacientes; además, sin CBAM se entrena más rápido. Iniciar el backbone con los pesos del Taller 3 (transfer learning) no mejoró el Dice en ningún conjunto, aunque redujo los fragmentos espurios (precisión 0.678 frente a 0.602).

Tabla 2. Ablación: Dice de fragmento y tiempo (* ajuste fino desde 256 px).

Escala	Modelo	Validación	Prueba	Entrenamiento
256 px	Base, con CBAM	0.695	0.676	5.2 h
256 px	Sin CBAM	0.736	0.667	3.2 h
256 px	Con transfer learning	0.658	0.661	4.0 h
384 px	Con CBAM	0.719	0.719	3.0 h*
384 px	**Sin CBAM (final)**	**0.793**	0.700	2.7 h*

Matriz de confusión de la clasificación (tabla 3). En los 4005 cortes de prueba (umbral 0.5) el sacro es la región más difícil: 76 cortes que el modelo no ve y 44 falsas alarmas. El F1 promedio aquí es 0.988; el 0.981 de la tabla 1 usa los 4821 cortes de los volúmenes completos, y los cortes de más, fuera de la pelvis, solo suman falsos positivos. Por píxel, cada región acierta entre 96.5 % y 97.7 %, casi todo el error es hueso marcado como fondo y la confusión entre huesos no pasa del 0.1 %.

Tabla 3. Matriz de confusión de la clasificación (4005 cortes de prueba).

Región	VN	FP	FN	VP	F1
Sacro	1623	44	76	2262	0.974
Coxal izq.	562	31	13	3399	0.994
Coxal der.	576	24	2	3403	0.996

Cinco peores casos (tabla 4). La galería muestra un corte por caso, el de más error. En los cinco el error está en los secundarios: se absorben en el principal, se funden entre sí o quedan partidos.

Tabla 4. Casos de prueba con menor Dice de fragmento y causa probable.

Caso	Dice	Qué falla	Causa probable
039	0.50	SA-2 y SA-3 absorbidos; 5 espurios	Secundarios del sacro pintados como el principal
085	0.55	SA-2 perdido; LI-1 (0.23) y LI-4 (0.04)	Confunde cuál fragmento del coxal izq. es el principal
002	0.61	RI-2 y RI-3 fundidos; espurio de 20 mL	Rama superior del coxal izq. separada como fragmento
084	0.64	LI-3 y LI-4 perdidos; 5 espurios	Fragmentos pequeños junto a la unión sacro–coxal izq.
015	0.66	SA-2 partido; LI-3 perdido; 7 espurios	Borde de contacto con semillas de más en el sacro

Distancia de separación: predicción frente a ground truth. De los 46 fragmentos secundarios de prueba, 25 se emparejaron con una predicción. En 20 de esos 25 el error es de 1 mm o menos (mediana de 0.0 mm), porque la mayoría está en contacto con su hueso tanto en la referencia como en la predicción. El error medio, de 4.0 mm, lo producen tres fragmentos que sí están desplazados (12.9, 35.1 y 50.8 mm en la referencia) y que el modelo midió como pegados (0.8 mm). Como no se separan bien, el error de la segmentación pasa directo a la medida, justo en los casos que más le importan al cirujano. Los otros 21 no tienen medida.

Robustez, SAM y latencia. Con la degradación más fuerte (ruido, desenfoque, resolución y contraste) la detección se mantiene (mAP@0.50 de 0.876) y el Dice de fragmento baja a 0.614. Como línea base usamos SAM [6] sin ajuste fino, con las cajas del modelo final como prompt: logra un Dice de 0.918 y un IoU de 0.851 por región, frente a 0.969 y 0.941 del modelo propio. La diferencia está sobre todo en el sacro (0.879 frente a 0.963), y SAM no separa fragmentos ni mide distancias. La inferencia toma ~13.5 ms por corte en GPU y entre ≈ 225 y ≈ 353 ms por corte en CPU según el equipo (1.3 a 2.3 min por TC).

5. Discusión y limitaciones

La parte anatómica funciona bien: encontrar, clasificar y delimitar cada hueso es preciso y aguanta la degradación. Lo difícil son los secundarios en contacto con su hueso. Los fragmentos principales llegan a un Dice de 0.93, pero los secundarios grandes tienden a quedar absorbidos por el principal (7 de 45 en validación sin CBAM, frente a 19 con CBAM), y trece variantes del post-proceso no lo corrigieron. Decidir cuál pieza es la principal es una propiedad 3D y la red decide corte a corte; ese mismo problema explica el error de distancia en los fragmentos desplazados. Además, el Dice no ve los fragmentos falsos: en validación se llegaron a predecir 216 para 90 reales, y con el umbral de 1 mL la precisión queda en 0.60. Con una sola semilla por modelo y 15 pacientes por partición, diferencias de ~0.02 no son concluyentes. El enunciado pide CBAM en el backbone: el diseño lo incluye y sus pesos se entregan, pero el modelo final no lo usa porque la ablación mostró que no aporta.

6. Conclusiones y uso de IA

Con una red multitarea propia de 6.75 M de parámetros, entrenada en pocas horas en una GPU de 6 GB, superamos las metas de clasificación y detección, pero no la de segmentación de fragmentos. La comparación de distancias muestra que el error de la medida nace en la segmentación de los fragmentos desplazados, y eso es lo que debería atacar un modelo 3D. Usamos IA generativa como apoyo en código, documentación y despliegue; cada uso y su análisis crítico están en IA_USAGE.md.

Referencias

[1] Y. Sang, Y. Liu, S. Yibulayimu et al., “Benchmark of Segmentation Techniques for Pelvic Fracture in CT and X-Ray: Summary of the PENGWIN 2024 Challenge”, IEEE Trans. Med. Imaging, vol. 45, no. 5, pp. 2212–2228, 2026, doi:10.1109/TMI.2025.3650126.

[2] Y. Liu, S. Yibulayimu, G. Zhu et al., “Automatic pelvic fracture segmentation: a deep learning approach and benchmark dataset”, Frontiers in Medicine, vol. 12, 1511487, 2025. Datos: doi:10.5281/zenodo.10927452.

[3] S. Woo, J. Park, J.-Y. Lee e I. S. Kweon, “CBAM: Convolutional Block Attention Module”, ECCV, 2018.

[4] Z. Tian, C. Shen, H. Chen y T. He, “FCOS: Fully Convolutional One-Stage Object Detection”, ICCV, 2019.

[5] O. Ronneberger, P. Fischer y T. Brox, “U-Net: Convolutional Networks for Biomedical Image Segmentation”, MICCAI, 2015.

[6] A. Kirillov et al., “Segment Anything”, ICCV, 2023.